

# 中山大学硕士学位论文

基于流数据的三维物体检测与追踪  
3D Streaming-based Object Detection and Tracking

学 位 申 请 人	郭叙森
指 导 老 师	黄凯 教授
专 业 名 称	计算机科学与技术

答辩委员会主席 (签名): \_\_\_\_\_  
答辩委员会委员 (签名): \_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_  
\_\_\_\_\_

二〇二〇 年 五 月 二十 日

## 论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：\_\_\_\_\_

日 期：        年    月    日

## 学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：

导师签名：

日期：        年    月    日

日期：        年    月    日

论文题目：基于流数据的三维物体检测与追踪

专业：计算机科学与技术

硕士生：郭叙森

指导老师：黄凯 教授

## 摘 要

近年来，借助深度学习技术，三维物体检测任务取得了许多令人瞩目的成就。这些进展也带动着众多自动驾驶创业公司蓬勃发展。然而，目前大多数三维物体检测方法都是针对单帧数据的，这些方法忽略了数据的时间连续性，无法利用帧与帧之间的相关信息，对技术的落地增加了不少难度。本工作旨在探索三维物体检测中时序信息的利用，通过深度学习技术去挖掘流数据中帧间相关性。为此，本文针对性地构建了一个基于关键帧的双路三维物体检测网络。该网络首先对关键帧进行物体检测，然后基于网络学习的时序信息，将关键帧的检测结果传播到非关键帧。该传播过程可以将不同帧的相同物体关联，因此在得到检测结果之后，追踪结果也很容易获得，从而使得本方法同时具备三维物体检测与追踪的能力。实验表明，本方法在速度与精度上都要优于同类型的单帧物体检测网络。另外，在 KITTI 数据集的目标追踪比赛中，本方法在 MOTA 和 MOTP 两个目标追踪的主要评估指标上分别取得了 76.68% 以及 81.65% 的成绩。

**关键词：**三维物体检测；多目标追踪；时序信息；关键帧；KITTI

Title: 3D Streaming-based Object Detection and Tracking  
Major: Computer Science and Technology  
Name: Guo Xusen  
Supervisor: Prof. Huang Kai

## ABSTRACT

Recent approaches for 3D object detection have made tremendous progresses due to the development of deep learning. However, previous researches for detection are mostly based on individual frames, leading to limited exploitation of information between frames. In this paper, we attempt to leverage the temporal information in streaming data and explore 3D streaming based object detection as well as tracking. Toward this goal, we set up a dual-way network for 3D object detection based on key frames, then propagate predictions to non-key frames through a motion based interpolation algorithm guided by temporal information. Our framework is not only shown to have significant improvements on object detection compared with frame-by-frame paradigm, but also proven to produce competitive results on KITTI Object Tracking Benchmark, with 76.68% in MOTA and 81.65% in MOTP respectively.

**Keywords:** 3D object detection; Multiple object tracking; Temporal information; Key frame; KITTI

# 目 录

第 1 章 引言	1
1.1 研究背景与意义	1
1.2 国内外研究进展	2
1.3 本文工作及创新点	5
1.4 文章组织与结构	6
第 2 章 目标检测与跟踪技术介绍	7
2.1 目标检测	7
2.2 目标跟踪	14
2.3 本章总结	17
第 3 章 流数据的三维目标检测与跟踪	18
3.1 框架整体结构	18
3.2 三维物体检测模块	19
3.3 Shared RPN 模块	19
3.4 时序信息处理模块	19
3.5 运动插值模块	22
3.6 多目标追踪	22
3.7 本章总结	22
第 4 章 实验过程与结果分析	23
4.1 KITTI 数据集介绍	23
4.2 数据预处理	23
4.3 模型训练	23
4.4 实验结果分析	23
4.5 结果展示	23
4.6 本章总结	23
第 5 章 总结与展望	24
5.1 全文总结	24
5.2 展望	24

参考文献 .....	25
攻读硕士学位期间发表学术论文情况 .....	28
致 谢 .....	29

# 第 1 章 引言

## 1.1 研究背景与意义

近几年来,深度学习的迅猛发展赋予了机器越来越强的智能。在这样的背景下,无人驾驶作为最能够体现机器智能的”潜力股”之一,受到了各行各业的普遍关注。无人驾驶要求车辆能够像人类一样识别道路场景,包括行人,车辆以及车道线等,并且能够根据这些信息高效地规划路径来实现与人类类似的驾驶行为。在无人驾驶的整个技术栈中,车辆的环境感知能力是最为关键的一环。目前无人驾驶车辆依赖多种传感器感知环境,譬如激光雷达 (LIDAR)、摄像头、毫米波雷达等。这些传感器的数据能够通过算法融合还原真实的三维环境,得到场景中物体的位姿与运动信息。

三维物体检测是无人驾驶环境感知的一个重要任务。该任务要求无人驾驶系统能够通过分析传感器采集的数据,计算出场景中各个目标的三维坐标以及位姿。相比于二维图像的物体检测任务,三维物体检测要更加困难。这是因为维度诅咒 (Curse of dimensionality) 的存在:当维度增加时,空间的体积增加得非常之快 (以指数增加),以致于可用的数据变得稀疏。三维物体检测的一大挑战,就是三维数据的稀疏性。目前无人驾驶中三维数据的获得主要是依靠激光雷达-高速旋转的激光发射器向周围发射激光,通过检测接收到反射回来光线的时间间隔来计算反射点的距离。激光雷达的线束对其分辨率有很大影响,特别是对于远距离的物体,在低线束 (16 线) 激光雷达中可能只有稀疏的几个点,完全无法分辨。然而高线束的激光雷达价格十分昂贵 (以 Velodyne 64 线激光雷达为例,其价格高达十几万美金),因此多数无人驾驶技术方案都需要在性能与价格之间做出权衡。

从使用数据的类型来看,目前针对三维环境的物体检测技术主要分为三大方向:基于图像的方案,基于点云数据的方案,以及多传感器数据融合方案。尽管如此,绝大多数方案都局限于使用一帧数据进行检测。对于真实场景的检测任务来说,数据都是以流的形式连续获取的。相比于单帧数据,流数据可以提供同

一目标在一段时间内的信息，该信息有利于检测算法筛除误检测的目标，这是因为噪声在时序上的连续性较差。另一方面，对于遮挡以及边界截断的目标，在流数据中可以利用前后帧的信息对其进行补全。另外一点值得注意的是，流数据有很强的数据冗余性，如果使用单帧物体检测算法，则需要逐帧进行检测，十分耗时；但是如果使用针对流数据的检测算法，则可以只对少数关键帧进行检测，然后将检测结果传播到非关键帧。因此，开发专门针对流数据的三维物体检测算法，能显著提高物体检测的准确率与效率。这从算法的落地来看，是十分有实践意义的。

## 1.2 国内外研究进展

目前国内外针对流数据的三维物体检测研究还较少，而基于单帧数据的三维物体检测以及基于视频流的二维物体检测的研究较为丰富。因此，本节分别从三维物体检测以及视频流物体检测概述前沿进展。另外，三维场景的多目标追踪研究进展也会进行简要说明。

### 1.2.1 三维物体检测

目前大多数三维检测研究可以归类为三大方向：基于图像，基于点云，以及基于多传感器融合。

(1) 基于图像的方法。基于图像的三维物体检测以 Mono3D [1] 和 3DOP [2] 为代表。这类方法只是用摄像头采集的图像数据，通过多视角图像融合来推断三维信息。由于图像数据没有深度信息，这类方法需要人工设计的几何特征来表征物体的深度信息，虽然数据采集简单，速度快，但是检测精度差。最近越来越多研究者探索基于双目摄像头数据的三维物体检测，例如 [TODO]。这类方法通过神经网络融合左右摄像头的的数据来预测物体的三维信息，从生物学上来说很接近人类的双眼视觉系统。然而由于神经网络的不确定性，以及双目视觉盲区的存在，该方法仍然有很多亟待解决的问题。

(2) 基于点云的方法。基于点云的方法可分为一步法和两步法。一步法即直接是端对端预测物体的三维位姿，这类方法根据点云的编码方式不同又可分为基于体素的方法以及基于投影的方法。基于体素的方法使用三维体素网格编码点云特征，每个体素立方体的值由该立方体内的点决定，从而将不规则的三维点云



数据编码成规则的三维体素数据, 便于后续使用神经网络进行特征提取。代表有 3D FCN [3], Vote3Deep [4] 以及 VoxelNet [5] 等。这类方法的一大缺点是体素大小不好确定, 太大的话信息损失严重, 太小则会造成巨大的计算量。另外, 这类方法需要使用到三维卷积, 因此很耗计算资源。基于投影的方法是将点云在高度方向进行投影, 将三维数据降维成二维的俯视图 (BEV, bird eye view) 数据。考虑到驾驶场景中, 道路基本是共面且水平的, 因此在高度方向上投影对物体的位姿信息基本没有损失。经过投影操作后, 就能直接使用二维图像物体检测的方法进行物体检测。PIXOR [6] 以及 Complex-YOLO [7, 8] 等属于这类方法。虽然降维能够带来速度的极大提升, 然而由于点云数据的稀疏性, 经过投影后目标的特征点损失很严重。特征点的不足会很大程度上影响检测结果的准确性, 特别是对于远处的目标以及小目标。两步法的思路是先对点云进行分割, 然后对于分割结果的每一个目标进行框回归, 得到目标的三维位姿信息。这类方法的代表有 [9]。两步法的不足之处是其检测结果非常依赖于分割结果, 且在框回归中, 对于点较少的远处目标, 三维位姿信息的恢复效果并不好。

(3) 基于多传感器融合的方法。点云的稀疏性以及图像缺少深度信息都限制着相应方法的准确率, 一个自然而然的想法就是能不能将这两种数据融合, 从而达到更好的检测结果。基于多传感器融合的方法通过算法融合点云数据以及图像数据, 从而提升三维物体检测的准确率。这类方法的代表有 F-PointNet [10], MV3D [11], AVOD [12] 等。这些方法的区别主要在于融合的方式不同, F-PointNet 首先使用二维物体检测方法检测出图像中的所有物体, 之后对于每个物体, 将其反投影回点云中得到一个视锥区域, 对该区域内的点进行分割然后再进行框回归。该方法通过先在图像中找出目标, 从而减少了在点云空间的搜索区域。然而, 该算法的准确率受二维物体检测很大, 在第一步没有检测出的物体, 之后没有其他办法弥补。MV3D 将二维物体检测中的区域提取网络 (Region Proposal Network, RPN) 扩展到三维, 提出了 3D RPN 分别提取点云以及图像特征, 然后通过一个特征融合模块得到融合特征, 最后进行三维物体检测。AVOD 在 MV3D 的基础上改进了特征提取模块, 引入的金字塔结构从而能够得到全分辨率的特征图, 提升了物体的定位精度, 特别对于小物体。本文工作基于 AVOD 框架并进行了改进, 使其能支持多针输入, 并且引入了时序信息处理模块。

### 1.2.2 视频流物体检测

视频流物体检测与单帧物体检测的主要区别在于是否利用了时序信息。对于视频流物体检测,时序信息是物体的位姿在时间上的连续性的抽象体现。目前,大多数视频流物体检测方法都是在两个层面利用时序信息,特征提取层面以及最终的框回归层面。对于特征处理层面,一般是根据运动信息将前后帧的特征整合到关键帧,以增加关键帧的物体特征。这个过程中需要使用到光流信息,即图像中各像素点的运动方向。代表有 FGFA [13] 系列工作。一般来说光流信息的获取比较困难,这也是限制该方法进一步发展的主要障碍。对于在框回归层面利用时序信息,主要的工作有 T-CNN [?] 与 Seq-NMS [14] 等。T-CNN 使用预先计算的光流信息将关键帧的检测结果传播到临近帧,而 Seq-NMS 则是通过整合连续几帧的高置信度的候选框来提升目标检测中非极大值抑制 (Non-Maximum Suppression, NMS) 算法的性能。最近,也有一些工作试图通过神经网络学习连续帧之间的时序信息,从而避免使用高代价的光流数据。这类方法的代表有 D&T [15]。D&T 提出了一个双路目标检测网络,可以同时时间视频流的目标检测以及目标追踪。该网络可以输入多帧数据进行检测,并且通过互相关操作 (Cross-correlation) 来学习相邻帧之间相同物体的对应关系以及偏移。本文的算法框架在一定程度上也借鉴了 D&T 的结构,不过我们在他的基础上进行了很大的改进,使其能够适应三维物体的流数据检测。

### 1.2.3 三维多目标追踪

目前基本上所有的三维多目标追踪方法都是先对流数据的每一帧进行目标检测,然后再将这些检测框关联起来,这种范式也被称为 *Tracking by Detection* [16]。三维多目标追踪的工作有很多,比较有代表性的有 FaF [17], 3D-CNN/PMBM [18] 以及 DSM [19] 等。FaF 使用首先将点云流数据结构化成四维张量,然后构建了一个简单的特征提取网络提取特征,最后使用不同的网络头分别预测得到三维目标检测,多目标追踪以及运动方向预测结果。该方法能够整合前  $n$  帧的检测结果得到精确的物体运动轨迹。然而该方法计算量巨大,并且网络参数调节需要有很高的技巧。3D-CNN/PMBM 首先构建神经网络从单张图像预测物体的三维位姿,然后将所有帧的检测框送入泊松多重伯努利 (Poisson Multi-Bernoulli Mixture,

PMBM) 混合追踪滤波器进行滤波, 得到最终的三维多目标追踪结果。该方法只使用单帧图像进行三维目标检测, 效果有限。DSM 首先使用单帧三维物体检测框架 MV3D [11] 对每一帧数据进行物体检测得到三维检测框, 然后通过一个匹配网络 (*Matching net*) 以及得分网络 (*Scoring net*) 关联所有的检测框。该方法需要对每一帧数据都进行检测, 并且帧与帧之间的时序信息基本上没有被使用, 因此不是针对流数据的高效方法。

### 1.3 本文工作及创新点

本文提出了一个双路物体检测与追踪 (**Dual-way Object Detection and Tracking, DODT**) 框架, 实现了流数据场景的高效三维物体检测与追踪。本框架的构建是基于以下几个观察: (1) 点云能够与图像融合从而丰富物体的视觉特征, 这点在 [11, 12] 中得到了证实; (2) 除了通过光流数据, 时序信息也能够通过计算相邻帧间的互相关信息, 这点通过 [15] 也能够得到验证; (3) 特征在连续帧之间的变化是连续的, 我们可以只对关键帧进行检测, 然后将结果传播到非关键帧, 这样可以极大的减少计算量。对于第一点, 本文借用了 AVOD[12] 中的数据融合方案, 将点云数据提供的 BEV 信息与图像融合。对于第二点, 本文构建了一个时序模块 (*Temporal module*), 该模块使用互相光操作在 BEV 空间中计算相邻关键帧的时序特征, 然后预测相同物体在不同关键帧中同时出现的概率以及偏移量。与 [15, 20] 不同的是, 本模块的互相关操作是在后候选框层面进行的, 不需要全局计算, 这极大地提高了模块的运行效率。对于最后一点, 我们将 DODT 框架的目标检测模块设计成了双路结构, 这样该模块就能够同时输入两帧相邻关键帧, 以保证后面时序模块的正确运行。另外, 为了进一步提高框架的效率, 本文还设计了一个共享 RPN (*Shared Region Proposal Network, Shared RPN*) 模块, 该模块可以生成供两检测分支共同使用的三维候选框。最后, 为了生成所有帧的检测结果, 本文设计了一个基于运动的框插值算法, 该算法利用关键帧的检测结果以及时序模块预测的信息, 插值生成非关键帧的检测结果。同时, 该差值算法还能够将不同帧的候选框关联起来, 得到多目标追踪结果。

本文的贡献及创新点如下:

- 本文提出了名为 DODT 的双路网络, 该网络能够同时精确地完成基于流

数据的三维物体检测以及多目标追踪任务。

- 本文提出了一个时序模块在候选框层面上编码相邻关键帧之间的时序信息，相比于 [15, 20] 中方法，该方法更加灵活，也更加高效。
- 本文设计了一个共享 RPN 模块，能够显著提高相邻多帧目标检测中候选框提取的效率。
- 本文开发了一个基于运动的框插值算法，能够有效的将关键帧的预测框传播到非关键帧，同时也能够将所有框关联起来，实现多目标追踪。

## 1.4 文章组织与结构

本文的主要内容分为五章。第一章为引言，介绍项目的研究背景和意义，国内外的研究进展以及本文工作的简单介绍和创新点；第二章介绍本工作涉及到的一些技术的基础理论，分为目标检测与目标追踪两大块；第三章详细地介绍了本文提出的框架的构造和原理，是全文的重点内容；第四章主要是介绍了本项目的实验设计，结果展示以及实验结果分析，该部分也是全文的重点内容；最后一章总结本文的工作，然后介绍本文工作的不足之处以及后续的实验计划。

## 第 2 章 目标检测与跟踪技术介绍

由于本工作涉及到的领域包括目标检测以及目标追踪,较为复杂。因此本文单独使用一章来介绍相关的背景知识,希望能为后续本文工作的介绍提供了技术参考。

### 2.1 目标检测

目标检测 (Object Detection) 作为计算机视觉中最基本的任务之一,一直以来都受到了学术界与产业界的极大关注。特别是在最近二十年,随着深度学习技术的飞速发展,神经网络已经是目标检测中必不可少的组成部分。可以说,是深度学习的引入将目标检测推向了新的高度,远远超出了传统目标检测方法的性能。以图像为例,目标检测需要在图片中精确找出物体所在的位置 (一般以矩形框出),并标注物体的类别。由于物体的尺寸变化范围很大,摆放物体的角度、姿势等也不确定,并且物体间也会有重叠,这些问题使得目标检测问题不是那么容易解决。现阶段基于深度学习的目标检测框架主要有两类,一类是以 Faster-RCNN 为代表的两阶段目标检测方法,另一类是以 YOLO 为代表的单阶段目标检测方法。本小节详细介绍了这两种框架发展历史以及结构细节与实现原理,此外,也简单介绍了三维目标检测相对于二维目标检测的改进。

#### 2.1.1 两阶段目标检测

目标检测任务包含目标识别以及目标定位两个子任务,一般的实现思路是先利用算法截取图片中可能作为目标的不同部分 (候选区域),然后分别送入一个分类器进行分类。将截取候选区域算法的实现与后续分类器的实现分开,这就是两阶段物体检测的实现思路。两阶段物体检测算法的代表是何凯明团队的系列工作。该系列历经 RCNN, Fast-RCNN 再到 Faster-RCNN,将两阶段物体检测框架不断完善,成为该领域的经典之作。

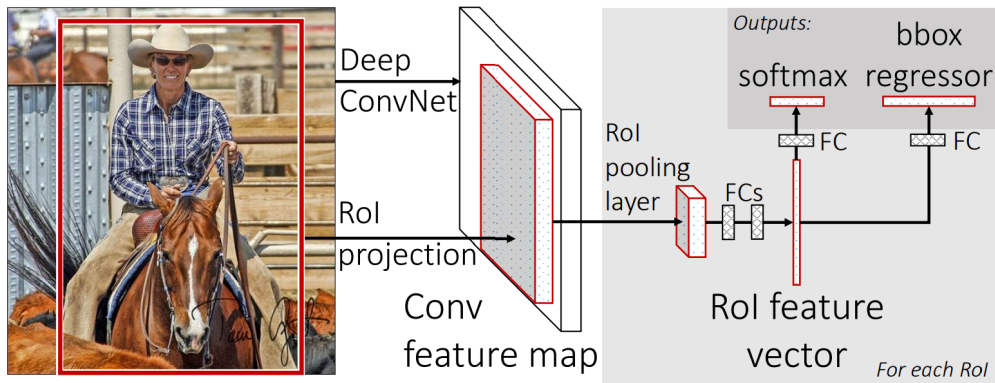


图 2-1 Fast-RCNN 结构示意

### 2.1.1.1 发展过程

RCNN 可以说是利用深度学习技术进行目标检测的开山之作。该工作使用选择性搜索 (Selective Search) 算法代替滑动窗口来截取候选区域，并且利用训练的神经网络对图片进行特征提取，然后使用 SVMs 进行类别判断。该工作奠定了两阶段目标检测框架的基本结构，即一个区域提取 (Region Proposal) 算法用于提取输入图像中可能是目标的区域，一个 CNN 网络用于提取区域特征，最后一个分类算法用于类别鉴定。在 RCNN 的基础上，RBG[TODO] 提出了 Fast-RCNN 算法。该算法借鉴了 SPP-Net 的实现，对 RCNN 做了改进，使得检测性能进一步提高，其结构如图 2-1 所示。具体而言有两个重大改进：（1）将候选区域提取阶段移到了图像特征提取之后，即只对原图做一次卷积，然后在特征图上运行候选区域提取算法得到候选区域特征图，然后将每一个特征图输入 ROI(region of interest) 层来将不同尺度的特征图转化为相同维度的特征向量，之后送入全连接层进行后续处理；（2）RCNN 训练神经网络提取图像特征，用支持向量机分类以及用回归模型精修边界框，然而 Fast-RCNN 利用两个全连接层 (Softmax Classifier, Bounding-Box Regressors) 将三个任务整合到一个模型里联合训练，这为之后的目标检测端对端训练打下了基础。

尽管 Fast-RCNN 相对于 RCNN 已经提速了不少，但要实现实时检测，速度还是不够，主要的速度瓶颈在候选区域提取阶段。基于 CPU 实现的 Selective Search 算法提取一幅图像的所有候选区域 (Proposals) 需要约 2s 时间，效率更高的 EdgeBoxes 算法虽然在一定程度上提高了候选区域提取的准确率和效率，但




图 2-2 Faster-RCNN 结构示意图

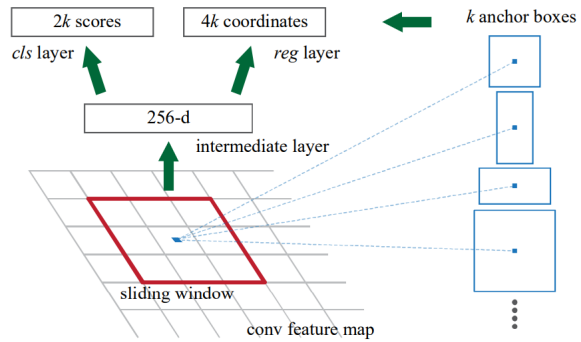


图 2-3 RPN 结构示意图

处理一幅图像仍然需要 0.2s。为了解决这个问题，2015 年微软亚洲研究院提出了 Faster-RCNN 算法，该算法引入了 RPN 网络 (Region Proposal Network)，使用神经网络来取代传统的区域提取算法，将单幅图像候选区域提取时间降到了 10ms。接下来本文将以 Faster-RCNN 为代表，重点介绍两阶段物体检测框架的结构与实现细节。

### 2.1.1.2 Faster-RCNN 框架结构

Faster-RCNN 框架由两大模块组成，候选框提取模块 (RPN) 和检测模块，如图 2-2 所示。在 Faster-RCNN 框架中，首先输入一幅图像，图像经过卷积神经网络提取特征得到特征图 (feature maps)，然后 RPN 模块输入特征图预测得到候选框 (proposals)，之后根据候选框去特征图中截取特征块，特征块经过 ROI Pooling 操作得到特征向量，最后送入检测头 (classifier) 和回归头 (regressor) 分别得到分类结果以及预测框。RPN 是 Faster-RCNN 新引进的模块，其结构如图 2-3 所示。在特征提取网络生成的特征图 ( $M \times N$ ) 上，使用  $n \times n$  的卷积核卷积生成  $M \times N \times k$  个维度为 256 的中间特征向量，之后输入分类全连接层 (cls layer) 和回归全连接层 (reg layer)，分别用来预测候选框的类别 (前景/背景， $M \times N \times 2 \times k$ ) 以及候选框的位置信息 (中心点坐标  $x, y$  以及宽高  $w, h$ ， $M \times N \times 4 \times k$ )。其中， $k$  表示对于特征图上的每一个像素点，都负责预测  $k$  个锚点框 (anchor boxes)，为满足候选框的尺寸变化， $k$  个锚点框有不同的尺寸和长宽比，例如 Faster-RCNN 中有三种尺寸： $128 \times 128, 256 \times 256, 512 \times 512$  (px)，三中长宽比：1 : 1, 1 : 2, 2 : 1，因此

$k = 3 \times 3 = 9$ ，意味着每个锚点负责预测 9 个不同的候选框。

### 2.1.1.3 Faster-RCNN 网络训练

构建了网络结构，网络的训练还需要准备训练数据，明确损失函数等。目标检测的训练数据一般有公开的数据集，如 COCO, PASCAL 等，然而 Faster-RCNN 还需额外训练 RPN 网络，因此需要准备 RPN 网络训练的标签。候选框标签的生成需要借助真实标签生成：首先根据上文中锚点的概念，以特征图尺寸为参照生成  $M \times N \times k$  个候选框，然后根据候选框与真实物体框的重叠程度（一般以候选框与真实框的交并比为量化指标）计算每个候选框的得分。得分可作为划分前景和背景的标准，譬如得分大于 0.65 划分为前景，小于 0.35 划分为背景，这样就得到了 RPN 网络的训练数据标签。

Faster-RCNN 的损失函数有两部分构成，RPN 损失和 Fast-RCNN 损失，并且这两部分损失又分别包括分类损失和回归损失。

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (2-1)$$

RPN 损失函数如公式 2-1 所示，其中第一部分为分类损失，第二部分为回归损失。分类损失计算了 RPN 预测生成的候选框的类别与标签的交叉熵损失  $L_{cls}$ ，交叉熵损失公式如 2-2 所示。其中  $p_i$  为预测生成的候选框类别， $p_i^*$  是标签值。RPN 网络生成的候选框分为前景和背景，前景标签为 1，背景为 0，因此可以用一个 one-hot 向量表示。

$$L_{cls} = -\log[p_i^* p_i + (1 - p_i^*)(1 - p_i)] \quad (2-2)$$

在训练中，RPN 网络生成的  $M \times N \times k$  个候选框，然而并不是每个候选框都会纳入损失值的计算范围，因为这些候选框有很多重叠的。Faster-RCNN 使用了非极大值抑制 (Non-Maximum Suppression, NMS) 算法进行初步筛选，减少重叠的候选框。非极大值抑制算法如 1 所示：对于 RPN 生成的候选框集合  $\mathcal{B}$  以及对应的置信度集合  $\mathcal{S}$ ，首先选择最大置信度的候选框  $M$ ，将其从  $\mathcal{B}$  中移除并加入最终候选框集合  $\mathcal{D}$ ；然后遍历  $\mathcal{B}$ ，移除与  $M$  的交并比 (Intersection of union, IoU) 大于阈值  $\epsilon$  的框；重复此过程，直到  $\mathcal{B}$  为空。通过选择合适的阈值 (Faster-RCNN 中为 0.7)，NMS 算法可以过滤大部分重叠的候选框，之后从中随机选取  $N_{cls}$  候选框计算分类损失，在 Faster-RCNN 中  $N_{cls} = 256$ 。



**Algorithm 1:** 非极大值抑制算法

---

```

1 输入:  $\mathcal{B} = \{b_1, \dots, b_N\}$ , RPN 生成候选框集合;  $\mathcal{S} = \{s_1, \dots, s_N\}$ , 生成候选框
   对应的置信度集合;  $\epsilon$ , 置信度阈值
2 初始化:  $\mathcal{D} \leftarrow \{\}$ 
3 while  $\mathcal{B} \neq \text{empty}$  do
4      $m \leftarrow \operatorname{argmax} \mathcal{S}$ 
5      $\mathcal{M} = b_m$ 
6      $\mathcal{D} \leftarrow \mathcal{D} \cup \mathcal{M}; \mathcal{B} \leftarrow \mathcal{B} - \mathcal{M}$ 
7 for  $b_i$  in  $\mathcal{B}$  do
8     if  $\operatorname{iou}(\mathcal{M}, b_i) \leq \epsilon$  then
9          $\mathcal{B} \leftarrow \mathcal{B} - b_i; \mathcal{S} \leftarrow \mathcal{S} - s_i$ 
10 输出:  $\mathcal{D}, \mathcal{S}$ 

```

---

RPN 回归损失计算预测的候选框与标签的  $\text{Smooth}_{L1}$  损失  $L_{reg}$ , 注意 RPN 回归损失只计算前景的损失, 因此  $L_{reg}$  前需乘以  $p_i^*$  (前景为 1, 背景为 0)。  $N_{reg} = N_{cls}$ , 为经过 NMS 算法过滤后随机选择的候选框数。  $\text{Smooth}_{L1}$  损失公式如 2-3 所示,

$$L_{reg}(t_i, t_i^*) = \begin{cases} 0.5(t_i - t_i^*)^2 & |t_i - t_i^*| \leq 1 \\ |t_i - t_i^*| - 0.5 & \text{otherwise} \end{cases} \quad (2-3)$$

其中  $t_i$  和  $t_i^*$  分别对应预测候选框以及真实候选框的信息。 需要注意,  $t_i = (t_i^x, t_i^y, t_i^w, t_i^h)$  为一四维偏移向量, 其计算公式如 2-4 所示。 其中  $(x_a, y_a, w_a, z_a)$  分别是对应锚点框中心的坐标以及宽高。 RPN 并不直接对候选框回归, 而是回归候选框与对应的锚点框的偏移, 这有利于网络的训练。

$$t_x = \frac{x - x_a}{w_a}; t_y = \frac{y - y_a}{h_a}; t_w = \log\left(\frac{w}{w_a}\right); t_h = \log\left(\frac{h}{h_a}\right) \quad (2-4)$$

Fast-RCNN 的损失和 RPN 类似, 同样由分类损失和回归损失组成。 不过 RPN 的分类损失是二分类的交叉熵损失, 而 Fast-RCNN 是多分类的交叉熵损失, 将类别标签转化为 one-hot 向量后并没有本质区别。 和 RPN 类似, Fast-RCNN 也不对所有 RoI 计算损失, 而是先通过更严格的 NMS 算法过滤 (Faster-RCNN 中阈值设置为 0.3), 然后随机选择一定数量的候选框进行损失值计算。 Fast-RCNN 的回

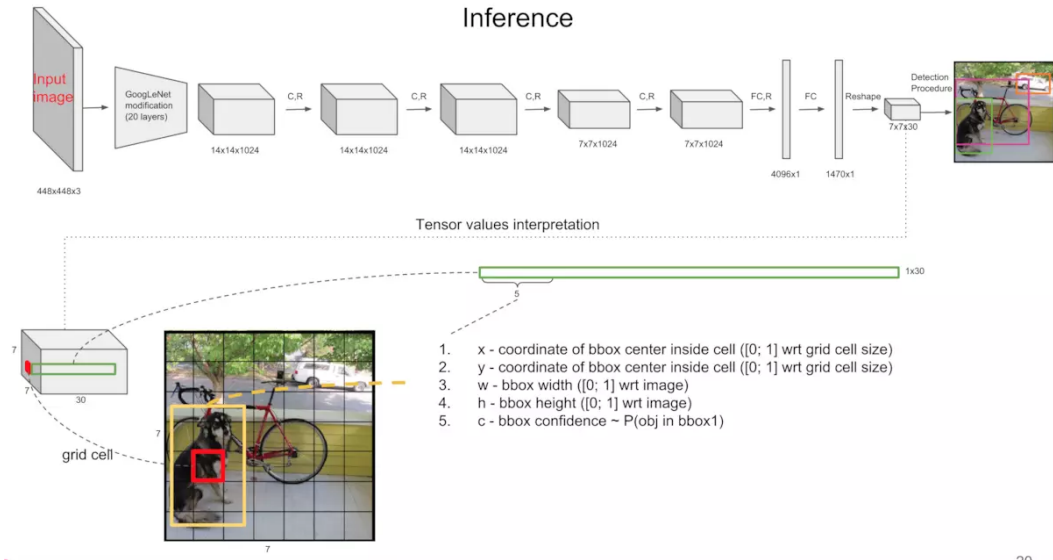


图 2-4 YOLO 结构示意图

归损失基本也和 RPN 的一致，不过这次是回归物体真实框与锚点框的偏移。

### 2.1.2 单阶段目标检测

从 RCNN 到 Fast-RCNN 再到 Faster-RCNN，一直采用先计算出候选区域然后再在候选区域上进行检测的设计范式。该模式可以获得很好的检测精度，然而在速度上还不佳，最好的 Faster-RCNN 只能达到 0.2s 一帧的检测速度，离实时检测还有较大差距。单阶段目标检测提供了另一种更直接的设计思路：不显式计算候选框，而是通过神经网络直接预测物体的位置与类别。该模式的代表工作有 YOLO 系列以及 SSD，本节以 YOLO 为例，介绍单阶段目标检测的实现方法以及网络训练。

YOLO 的整体架构如图 2-4所示。与 RCNN 系列工作不同，YOLO 将目标检测作为回归任务来解决。YOLO 首先将输入图像宽高调整到  $448 \times 448$ ，然后输入到由 GoogLeNet 改进的网络中，最后输出一个维度为  $S \times S \times (B \times 5 + C)$  的张量  $\mathcal{T}$ 。 $\mathcal{T}$  可以这么理解，首先将一幅图像分成  $S \times S$  (YOLO 是  $7 \times 7$ ) 个网格，对于每个网格  $s$ ，其对应着  $\mathcal{T}$  中的一项维度为  $1 \times (B \times 5 + C)$  的向量  $t$ 。如果一个目标物体的中心落在  $s$  上，则  $s$  负责预测该物体，预测结果编码在向量  $t$  中。 $t$  维度为  $B \times 5 + C$ ，其中  $B$  表示每个网格预测两个边界框 (bounding box, bbox)；5 编码了 bbox 的信息，分别是  $(x, y, w, h, c)$ ，代表 bbox 中心点坐标、宽高以及置信

度； $C$  表示需要预测  $C$  个类，每个值表示预测为该类的概率值  $Pr(class_i|object)$ 。

和 Faster-RCNN 类似，YOLO 也不是直接回归出物体的实际坐标和宽高，而是 **bbbox** 相对于单元格的偏移量。对于向量  $t = (x, y, w, h, c)$ ， $(x, y)$  的计算公式如2-5所示，其中  $(x_c, y_c)$  是 **bbbox** 中心点的实际坐标， $(w_i, h_i)$  是图像的宽高， $x_{col}, y_{col}$  是单元格的坐标。最终预测出来的  $(x, y)$  是经过归一化处理的，中心相对于单元格的偏移。 $(w, h)$  的计算公式如2-6所示，是 **bbbox** 相对于整张图像的比例。置信度  $c$  的计算公式如2-7所示，由两部分组成， $Pr(object)$  表示单元格内是否有物体，有为 1，没有则为 0； $IoU_{Pred}^{Truth}$  表示 **bbbox** 位置的准确度，用 IoU 衡量。

$$x = \frac{x_c}{w_i} S - x_{col}; y = \frac{y_c}{h_i} S - y_{row} \quad (2-5)$$

$$w = \frac{w_b}{w_i}; h = \frac{h_b}{h_i} \quad (2-6)$$

$$c = Pr(object) * IoU_{Pred}^{Truth} \quad (2-7)$$

在测试阶段，网络最终输出为一个  $S \times S \times (B \times 5 + C)$ ，其中包含  $S \times S \times B$  个预测框，每个预测框的最终概率为  $Pr(class_i|object) * c$ ，为综合了定位误差和分类误差的 20 维向量。最后这  $S \times S \times B \times C$  列的结果送入 NMS 算法去除重复的检测框，得到最终的检测结果。

YOLO 的损失函数设计比较复杂，如公式2-8所示。YOLO 的损失函数都采用平方和损失，可分为五部分来看：

$$\begin{aligned} L_{yolo} = & \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{i,j}^{obj} (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \\ & + \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{i,j}^{obj} \left( \sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left( \sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{i,j}^{obj} (C_i - \hat{C}_i)^2 \\ & + \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{i,j}^{noobj} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{obj} \sum_{c \in classes} (p_i(c) - \hat{p}_i(c))^2 \end{aligned} \quad (2-8)$$

第一部分为 **bbbox** 中心坐标的误差，其中  $\mathbb{1}_{i,j}^{obj}$  表示判断第  $i$  个网格中第  $j$  个 **bbbox** 是否负责预测该物体。第二部分为 **bbbox** 宽高的误差，由于在对不同大小的 **bbbox**

的预测中, 小  $\text{bbox}$  预测偏离的容忍程度比大  $\text{bbox}$  要小很多, 而平方和损失对  $\text{bbox}$  的尺度并不敏感。为了解决这个问题, YOLO 使用宽高的平方根代替原来的宽高。第三部分为含有物体的  $\text{bbox}$  的置信度预测误差, 第四部分为不含物体的  $\text{bbox}$  的置信度预测误差。最后一部分是对  $\text{bbox}$  类别预测的误差, 其中  $1_i^{obj}$  表示是否有物体落在单元格  $i$  中。另外, 为了平衡各种损失之间的比例, YOLO 还加入了  $\lambda_{coord}, \lambda_{noobj}$  作为超参数平衡各部分损失。

YOLO 由于没有显式的预测候选框的过程, 因此检测速度很快。但是由于网格的设定, YOLO 对相互靠的很近的物体 (中心可能落在同一个单元格内), 还有很小的物体检测效果不好, 这是由于一个单元格只预测一个类。另外, YOLO 对于同一类物体出现不常见的长宽比等情况的泛化能力较差。这些问题在其后的 YOLOv2、YOLOv3 中有探究。

### 2.1.3 三维目标检测

三维目标检测目前有两大类, 一类是基于二维目标检测进行扩展到三维, 一类是先进进行点云语义分割, 然后对分割后的每个类别的点进行聚类, 之后在进行物体框的回归。直接扩展二维目标检测方法的有基于两阶段目标检测的 MV3D、AVOD 等, 基于单阶段目标检测的 VoxelNet 等。在模型框架层面, 这一大类的三维目标检测和二维的没有多大区别, 只是需要先将三维点云编码为适合卷积的数据格式, 然后将二维边框编码扩展到三维, 以及损失函数做出相应的修改。具体的改动将会在下一章介绍本文方法时详细介绍。另一类先分割再回归框的方法有 PointRCNN 等, 由于这类方法与本文方法差距较大, 这里不过多介绍。

## 2.2 目标跟踪

由于本工作也涉及到一些目标跟踪方面的应用, 因此本文也简单介绍下目标跟踪的一些基本知识。目标跟踪问题是指给定第一帧物体的位置, 根据算法预测出后续帧中该物体的位置。根据追踪物体的数量的不同, 目标追踪分为单目标追踪 (Single Object Tracking, SOT) 和多目标追踪 (Multiple Object Tracking, MOT)。SOT 与 MOT 虽然都属于目标跟踪, 但是确实两个差别很大的研究方向。由于本工作只涉及到多目标跟踪, 因此会重点介绍, 而单目标跟踪只会简单叙述其基本原理。

### 2.2.1 单目标跟踪

单目标跟踪只针对单个物体进行追踪，其算法实现的基本思路如下：首先根据首帧提供的物体信息提取目标物体特征，例如灰度特征、颜色特征、纹理特征或者使用神经网络提取的视觉特征；然后基于帧间的目标运动关系，构建运动模型，经典的运动模型如均值偏移、滑动窗口、卡尔曼滤波以及粒子滤波等；之后根据运动模型确定的后续帧目标位置信息，提取该图像区域特征后输入外观模型与首帧物体特征进行对比判断；最后需要一个在线更新机制在跟踪过程中不断更新外观模型，使得模型能够捕捉目标的变化，适应长距离的跟踪。

学术界针对单目标追踪有大量的研究，如首次将相关滤波引入单目标跟踪的 MOSSE[21] 以及后续在此基础上发展的 KCF[22]、DSST[23]、C-COT[24] 以及 ECO[25] 等。另外，这些年基于孪生网络的单目标追踪模型发展迅速，如首先开创端对端深度学习式相关滤波方法先河的 SiamFC[26]，以及加入了 RPN 应对尺度变化的 SiamRPN[27] 以及其改进版本 DaSiamRPN[28] 等。从近几年的单目标跟踪研究可以看出，深度学习技术也在该领域也引发了技术革新。

### 2.2.2 多目标跟踪

多目标跟踪同时对多个物体进行跟踪，相比于单目标跟踪，其实现难度更大，因此进展较为缓慢。多目标跟踪一般会涉及到目标出现、遮挡以及离开视野等复杂情况。目前学术界针对多目标跟踪的主流实现思路是基于检测的跟踪 (Detection-Based Tracking)，该方法要求先由一个目标检测器将每一帧的目标都检测出来，然后再使用匹配算法将不同帧的同一物体相关联。按照处理方式，多目标跟踪算法可分为在线跟踪 (Online Tracking) 以及离线跟踪 (Offline Tracking)。在线跟踪要求算法只能根据当前帧以及之前帧的信息得出当前帧的跟踪结果，而离线跟踪允许算法利用所有帧的信息，获取全局最优解。相对于离线跟踪，在线跟踪更适合实际应用场景。例外，还有一种近似在线跟踪 (Near Online Tracking) 方法，该方法利用当前帧一定窗口范围内的帧的信息得出当前帧的跟踪结果，是一种折中方法，只会导致些许延迟。

目前多目标跟踪算法基本是使用现有的检测器模型得到所有帧的检测结果，然后设计数据关联算法得到多目标跟踪结果。例如 SORT[29] 使用 Faster-RCNN

作为目标检测器得到检测结果，然后使用中心坐标、面积、长宽比等对目标进行建模，使用卡尔曼滤波预测目标的后续状态，并将预测结果与实际结果进行匹配从而得到最终结果。在此基础上，作者使用了深度卷积神经网络提取目标特征作为匹配基础改进 SORT 而得到 DeepSORT[[30]。此外，还有一种比较简单的，使用前后两帧各目标框的 IoU 进行关联的 IoU Tracker[31]，该算法严重依赖于检测框的准确率。为了改善对检测结果精度的依赖，作者之后推出了改进版 V-IOU Tracker[32]，该算法加入了检测框的长程连续性特征，没有检测出的目标不再认为立即消失，而是会根据其运动趋势保持更新一定时间步长。本工作所使用的目标跟踪算法是基于 V-IOU Tracker 算法改进的。

多目标跟踪的性能评价指标和单目标跟踪有很大不同，当前学术界最常使用的衡量指标为 CLEAR MOT[33] 论文提出的多目标追踪准确度 (Multiple Object Tracking Accuracy, MOTA) 和多目标追踪精确度 (Multiple Object Tracking Precision, MOTP)。其中 MOTA 的计算公式如2-9所示，其中  $t$  表示帧数， $m_t, fp_t, mme_t$  分别是  $t$  帧时漏检、误检以及错误匹配的数量， $g_t$  为  $t$  帧中的真实标签。从公式可以看出 MOTA 可以分为三部分， $\bar{m}$  为漏检率， $\bar{fp}$  为误检率， $\bar{mme}$  为错误匹配率，这三种错误率的总和就是总错误率。MOTA 直观的给出了衡量算法连续跟踪识别目标的能力，不过没有涉及到目标的检测位置精确度。

$$\begin{aligned}
 MOTA &= 1 - (\bar{m} + \bar{fp} + \bar{mme}) \\
 &= 1 - \left( \frac{\sum_t m_t}{\sum_t g_t} + \frac{\sum_t fp_t}{\sum_t g_t} + \frac{\sum_t mme_t}{\sum_t g_t} \right) \\
 &= 1 - \frac{\sum_t (m_t + fp_t + mme_t)}{\sum_t g_t}
 \end{aligned} \tag{2-9}$$

另一个指标 MOTP 与 MOTA 互补，其衡量跟踪目标位置的精确度，而不衡量跟踪识别目标的能力。MOTP 的计算公式如2-10所示，其中  $t$  表示帧数， $i$  表示第  $t$  帧第  $i$  个目标-预测匹配对， $d_t^i$  表示第  $t$  帧中第  $i$  个目标-预测匹配对的位置误差， $c_t$  表示第  $t$  帧中总匹配对的个数。在计算 MOTA 和 MOTP 时，都是基于整个跟踪过程计算平均值的，而不是基于每一帧的结果，这是因为基于单帧计算然后再求平均会导致和直观上不同的结果。

$$MOTP = \frac{\sum_{i,t} d_t^i}{\sum_t c_t} \tag{2-10}$$

除了 MOTA 与 MOTP，为了更好的在轨迹层面上衡量多目标追踪，学术界一

般还会引入其他指标。例如多数追踪率 (Mostly Tracked, MT)、多数丢失率 (Mostly Lost, ML)、ID 切换次数 (ID-switches, IDS)、片段数 (Fragmentations, FM)。其中 MT 目标的大部分被追踪到的轨迹占比 (大于 80%), ML 表示目标的大部分跟丢的轨迹占比 (小与 20%), IDS 为一条跟踪轨迹改变目标编号的次数, FM 为真实轨迹被打断的次数。本工作使用 MOTA、MOTP 以及以上四种指标评估多目标跟踪算法的性能。

### 2.3 本章总结

本章主要介绍了本文涉及到的两个领域, 目标检测与目标跟踪的基本技术原理。首先介绍了两类目标检测框架的网络结构和训练方法, 其中两阶段目标检测以 Faster-RCNN 作为代表进行介绍, 而单阶段目标检测则以 YOLO 为代表进行介绍。之后, 本章简单介绍了单目标跟踪算法的实现思路和几种经典算法。本章最后介绍了多目标跟踪的实现方式和几种典型算法, 以及多目标追踪性能的评价指标。该章的内容是为下一章中本工作方法介绍的时候提供技术参考, 本章涉及到的技术原理, 下章将不再深入介绍。

## 第 3 章 流数据的三维目标检测与跟踪

本章将详细介绍本工作提出的流数据三维目标检测与跟踪框架 **DODT** (**Dual-way Object Detection and Tracking**)。本章先介绍 DODT 的整体网络架构, 然后再重点分析各个模块的功能以及实现。

### 3.1 框架整体结构

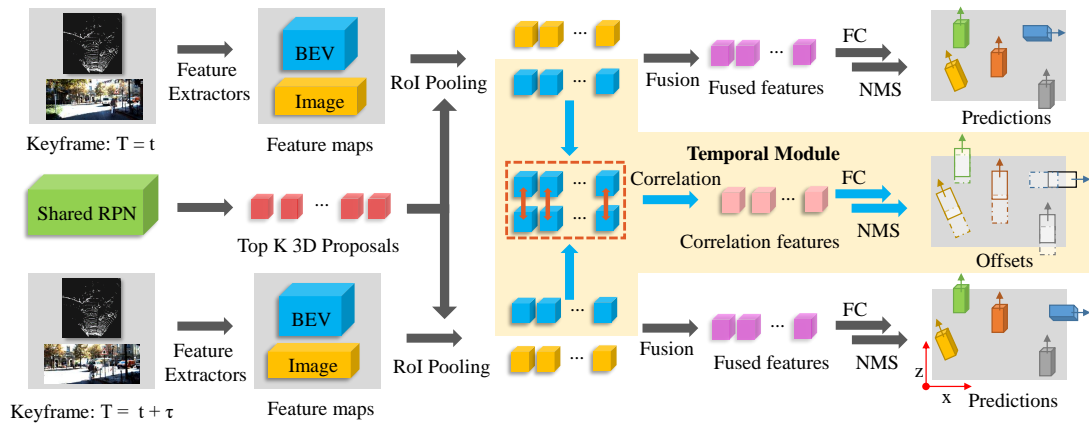


图 3-1 DODT 框架结构。浅黄色区域为时序处理模块。

DODT 网络是双路结构, 其结构如图 3-1 所示。DODT 由四个小模块组成: 三维物体检测模块、Shared RPN 模块、时序信息处理模块以及运动插值模块。三维物体检测模块有两个分支, 分别负责检测两相邻关键帧中的物体。检测模块的网络结构是基于 AVOD[12] 构建的, 为二阶段物体检测框架的三维扩展, 该模块的详细结构将在 3.2 节介绍。Shared RPN 模块负责生成二阶段物体检测中的候选框, 与传统 RPN 不同的是, Shared RPN 生成的 3D 候选框可以被两个三维检测分支共同使用, 该模块将在 3.3 节详细介绍。时序处理模块为图 3-1 的浅黄色区域, 该模块通过对相邻关键帧的点云俯视图 (Bird Eye View, BEV) 特征匹配块进行相关 (correlation) 操作提取帧间的时序信息, 然后预测同一物体在两关键帧的位置位置偏移。3.4 节将详细介绍时序处理模块的实现原理。运动插值模块主要是由独立于网络结构的运动插值算法构成, 该算法使用三维物体检测模块对两关键帧的检测结果以及时序处理模块输出的位置偏移信息, 将关键帧



的检测结果传播到非关键帧，实现流数据的三维物体检测与追踪。该算法的详细流程将会在 3.5 节重点介绍。

## 3.2 三维物体检测模块

DODT 框架的三维物体检测模块融合了点云与图像信息，预测自动驾驶场景中车辆的三维位姿信息。由于该检测模块是基于 AVOD[12] 网络，为二阶段物体检测模块，因此包含候选框提取网络。由于本框架的候选框提取网络与 AVOD 有所不同，因此将在下一节详细介绍。本节不展开介绍候选框提取环节。本节将依次介绍数据预处理、特征提取、RoI 池化、特征融合以及最终的预测框生成等物体检测中的关键环节。

### 3.2.1 数据预处理

DODT 融合 RGB 图像数据以及激光雷达数据进行三维物体检测，因此每一帧数据都同时包含图像以及点云。

### 3.2.2 特征提取

### 3.2.3 RoI 池化

### 3.2.4 特征融合

### 3.2.5 预测框生成

## 3.3 Shared RPN 模块

## 3.4 时序信息处理模块

$$\delta^{t,t+\tau} = \begin{cases} \left( \frac{d_x^{t+\tau}-d_x^t}{d_w^t}, \frac{d_z^{t+\tau}-d_z^t}{d_l^t}, \frac{d_{ry}^{t+\tau}-d_{ry}^t}{d_{ry}^t} \right) & p_{co} = 1.0 \\ (0.0, 0.0, 0.0) & otherwise \end{cases} \quad (3-1)$$

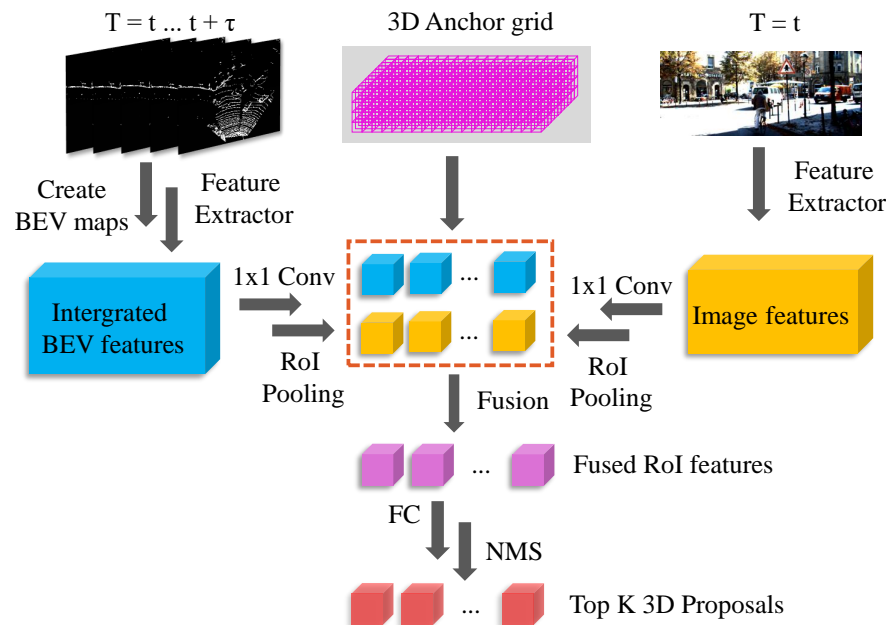


图 3-2 Shared RPN 模块。




图 3-3 绿色框是五帧中目标的标签框，红色框是为训练 *Shared RPN* 而新生成的共享候选框标签。

**Algorithm 2:** 基于运动模型的插值算法 (MoI Algorithm)

---

```

1  输入:  $D^t = [d_0^t, d_1^t, \dots, d_{N_t}^t], D^{t+\tau} = [d_0^{t+\tau}, d_1^{t+\tau}, \dots, d_{N_{t+\tau}}^{t+\tau}]$ ,
       $\Delta^{t,t+\tau} = [\delta_0^{t,t+\tau}, \delta_1^{t,t+\tau}, \dots, \delta_{N_{max}}^{t,t+\tau}], N_{max} = \max\{N_t, N_{t+\tau}\}$ 
2  输出:  $D = [D^t, D^{t+1}, \dots, D^{t+\tau}]$ 
3  初始化:  $D_{temp} = D^{t+\tau}, D, p_{co}^{max} = 0.5$ 
4  for  $d_i^t$  in  $D^t$  do
5       $\Delta d_i^{t,t+\tau} = (d_{i,w}^t \cdot \delta_{i,x}^{t,t+\tau}, 0, d_{i,l}^t \cdot \delta_{i,z}^{t,t+\tau}, 0, 0, d_{i,ry}^t \cdot \delta_{i,ry}^{t,t+\tau})$ 
       $d' = \text{getMatched}(d_i^t + \Delta d_i^{t,t+\tau}, D_{temp})$ 
6      if  $d'$  then
7           $d_i^{t+1}, \dots, d_i^{t+\tau-1} = \text{Interpolate}(d_i^t, d')$ 
8          remove  $d'$  from  $D_{temp}$ 
9      else if  $p_{co}^i \geq p_{co}^{max}$  then
10          $d_i^{t+1}, \dots, d_i^{t+\tau} = \text{Interpolate}(d_i^t, d_i^t + \Delta d_i^{t,t+\tau})$ 
11     else
12         generate  $(d_i^{t+1}, \dots, d_i^{t+\tau-1})$  by motion model
13 if  $D_{temp}$  is not empty then
14     for  $d_j^{t+\tau}$  in  $D_{temp}$  do
15         if  $p_{co}^j \geq p_{co}^{max}$  then
16              $d_j^t, \dots, d_j^{t+\tau-1} = \text{Interpolate}(d_j^{t+\tau} - \Delta d_j^{t,t+\tau}, d_j^{t+\tau})$ 
17         else
18             generate  $(d_j^{t+1}, \dots, d_j^{t+\tau-1})$  by motion model

```

---

### **3.5 运动插值模块**

### **3.6 多目标追踪**

### **3.7 本章总结**

## 第 4 章 实验过程与结果分析

### 4.1 KITTI 数据集介绍

### 4.2 数据预处理

### 4.3 模型训练

### 4.4 实验结果分析

#### 4.4.1 消融实验

#### 4.4.2 流数据检测结果分析

#### 4.4.3 多目标跟踪实验分析

### 4.5 结果展示

### 4.6 本章总结

## 第 5 章 总结与展望

### 5.1 全文总结

### 5.2 展望

## 参考文献

- [1] Chen X, Kundu K, Zhang Z, *et al.* Monocular 3D Object Detection for Autonomous Driving [C]. In 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 2016: 2147–2156.
- [2] Chen X, Kundu K, Zhu Y, *et al.* 3d object proposals using stereo imagery for accurate object class detection [J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 40 (5): 1259–1272.
- [3] Li B. 3d fully convolutional network for vehicle detection in point cloud [C]. In 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017: 1513–1518.
- [4] Engelcke M, Rao D, Wang D Z, *et al.* Vote3deep: Fast object detection in 3d point clouds using efficient convolutional neural networks [C]. In 2017 IEEE International Conference on Robotics and Automation (ICRA), 2017: 1355–1361.
- [5] Zhou Y, Tuzel O. Voxelnet: End-to-end learning for point cloud based 3d object detection [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 4490–4499.
- [6] Yang B, Luo W, Urtasun R. Pixor: Real-time 3d object detection from point clouds [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7652–7660.
- [7] Simon M, Milz S, Amende K, *et al.* Complex-YOLO: An Euler-Region-Proposal for Real-Time 3D Object Detection on Point Clouds [C]. In European Conference on Computer Vision, 2018: 197–209.
- [8] Simon M, Amende K, Kraus A, *et al.* Complexer-YOLO: Real-Time 3D Object Detection and Tracking on Semantic Point Clouds [C]. In The IEEE Conference on Computer Vision and Pattern Recognition (CVPR) Workshops, June 2019.
- [9] Shi S, Wang X, Li H. Pointcnn: 3d object proposal generation and detection from point cloud [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 770–779.
- [10] Qi C R, Liu W, Wu C, *et al.* Frustum pointnets for 3d object detection from rgb-d data [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 918–927.
- [11] Chen X, Ma H, Wan J, *et al.* Multi-view 3d object detection network for autonomous driving [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1907–1915.
- [12] Ku J, Mozifian M, Lee J, *et al.* Joint 3d proposal generation and object detection from view aggregation [C]. In 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2018: 1–8.
- [13] Zhu X, Wang Y, Dai J, *et al.* Flow-guided feature aggregation for video object detection [C]. In Proceedings of the IEEE International Conference on Computer Vision, 2017: 408–417.

- [14] Han W, Khorrami P, Paine T L, *et al.* Seq-nms for video object detection [J]. arXiv preprint arXiv:1602.08465, 2016.
- [15] Feichtenhofer C, Pinz A, Zisserman A. Detect to track and track to detect [C]. In Proceedings of the IEEE International Conference on Computer Vision, 2017: 3038–3046.
- [16] Lenz P, Geiger A, Urtasun R. FollowMe: Efficient online min-cost flow tracking with bounded memory and computation [C]. In Proceedings of the IEEE International Conference on Computer Vision, 2015: 4364–4372.
- [17] Luo W, Yang B, Urtasun R. Fast and furious: Real time end-to-end 3d detection, tracking and motion forecasting with a single convolutional net [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 3569–3577.
- [18] Scheidegger S, Benjaminsson J, Rosenberg E, *et al.* Mono-camera 3d multi-object tracking using deep learning detections and pmbm filtering [C]. In 2018 IEEE Intelligent Vehicles Symposium (IV), 2018: 433–440.
- [19] Frossard D, Urtasun R. End-to-end Learning of Multi-sensor 3D Tracking by Detection [C]. In 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018: 635–642.
- [20] Dosovitskiy A, Fischer P, Ilg E, *et al.* FlowNet: Learning optical flow with convolutional networks [C]. In Proceedings of the IEEE international conference on computer vision, 2015: 2758–2766.
- [21] Bolme D S, Beveridge J R, Draper B A, *et al.* Visual object tracking using adaptive correlation filters [C]. In 2010 IEEE computer society conference on computer vision and pattern recognition, 2010: 2544–2550.
- [22] Henriques J F, Caseiro R, Martins P, *et al.* High-speed tracking with kernelized correlation filters [J]. IEEE transactions on pattern analysis and machine intelligence, 2014, 37 (3): 583–596.
- [23] Danelljan M, Häger G, Khan F, *et al.* Accurate scale estimation for robust visual tracking [C]. In British Machine Vision Conference, Nottingham, September 1-5, 2014, 2014.
- [24] Danelljan M, Robinson A, Khan F S, *et al.* Beyond correlation filters: Learning continuous convolution operators for visual tracking [C]. In European conference on computer vision, 2016: 472–488.
- [25] Danelljan M, Bhat G, Shahbaz Khan F, *et al.* Eco: Efficient convolution operators for tracking [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2017: 6638–6646.
- [26] Bertinetto L, Valmadre J, Henriques J F, *et al.* Fully-convolutional siamese networks for object tracking [C]. In European conference on computer vision, 2016: 850–865.
- [27] Li B, Yan J, Wu W, *et al.* High performance visual tracking with siamese region proposal network [C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 8971–8980.
- [28] Zhu Z, Wang Q, Li B, *et al.* Distractor-aware siamese networks for visual object tracking [C]. In Proceedings of the European Conference on Computer Vision (ECCV), 2018: 101–117.
- [29] Bewley A, Ge Z, Ott L, *et al.* Simple online and realtime tracking [C]. In 2016 IEEE International Conference on Image Processing (ICIP), 2016: 3464–3468.



- [30] Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric [C]. In 2017 IEEE international conference on image processing (ICIP), 2017: 3645–3649.
- [31] Bochinski E, Eiselein V, Sikora T. High-speed tracking-by-detection without using image information [C]. In 2017 14th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS), 2017: 1–6.
- [32] Bochinski E, Senst T, Sikora T. Extending IOU based multi-object tracking by visual information [J]. AVSS. IEEE, 2018.
- [33] Bernardin K, Stiefelhagen R. Evaluating multiple object tracking performance: the CLEAR MOT metrics [J]. EURASIP Journal on Image and Video Processing, 2008, 2008: 1–10.

### 攻读硕士学位期间发表学术论文情况

1. The paper title [J/C...]. Publish whereabouts, 2014, 21(3): 288-291. （第一作者，导师为第一作者）（与学位论文第 n 章相关）(盲审时，不要出现名字)
2. Authors. The paper title [J/C...]. Publish whereabouts, 2014, 21(3): 288-291. (提交时)

## 致 谢

谨此向我的导师张三教授致以衷心的感谢和崇高的敬意！本论文的工作是在张老师的悉心指导下完成的。在传授予我专业知识和宝贵经验的同时，张老师以其严谨的治学态度和精益求精的工作作风不断促进论文相关工作的进行，使我受益匪浅。

在攻读硕士的这三年里，导师和实验室的同学们不仅为我创造了优越的科研和学习环境，使我得以在计算机科学领域中自由翱翔，同时在思想上、人生态度和意志品质方面给予了谆谆教诲，这些教益必将激励着我在今后的人生道路上奋勇向前。特别感谢实验室的甲师兄、乙同学以及其他师弟师妹，他们不仅在学术上给了我许多指引和建议，而且在生活上予以帮助，从他们身上我学到了很多知识。

感谢王五老师及其实验室的同学在领域一、领域二方面的学习给予我的帮助。他们开创性的研究拓展了我的学术视野，无数次的争论和探讨使我的研究工作有了长足的进展。

由衷感谢我的室友 A、B 和 C 同学，以及其他经常到我们宿舍进行学习交流的 D、E、F 和 G 同学，是他们令我的学习生活都更加充满动力。衷心的感谢我的父母和其他亲朋好友对我的关心、支持和理解，没有他们对我的关心、鼓励和支持，我无法完成现在的硕士学业。

最后，感谢所有曾经教育和帮助过我的所有老师。衷心地感谢为评阅本论文而付出宝贵时间和辛勤劳动的专家和教授们！

郭叙森

二〇二〇年五月二十日